

第九届中国数据库技术大会 DATABASE TECHNOLOGY CONFERENCE CHINA 2018

# Spark Streaming在滴滴的大规模实践

赵士杰







# 提纲

- ➤ Spark Streaming特点及优势
- ➤ Spark Streaming在滴滴使用场景
- ➤ Spark Streaming最佳实践









## 01 Spark Streaming特点及优势









#### Spark Streaming特点



- 1. Spark streaming是Spark核心API的一个扩展
- 2. Micro-Batch模式、秒级延时
- 3. 离线和实时统一编程框架









#### Spark Streaming优势

相比其他流式系统的(storm、Flink等)优势:

- 1. 生态丰富
- 2. 吞吐量大
- 3. 非常丰富的算子
- 4. 相对比较稳定









#### 02 Spark Streaming在滴滴的使用场景





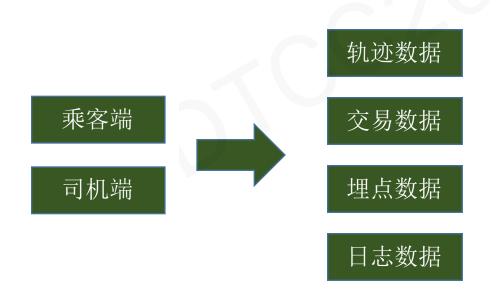




#### 滴滴实时场景

滴滴拥有非常丰富的实时数据及计算场景

- 1. 滴滴核心业务是一个在线交易系统
- 2. 滴滴有丰富的实时轨迹数据
- 3. 海量的实时数据需要强大的实时计算能力









#### Spark Streaming在滴滴的业务规模

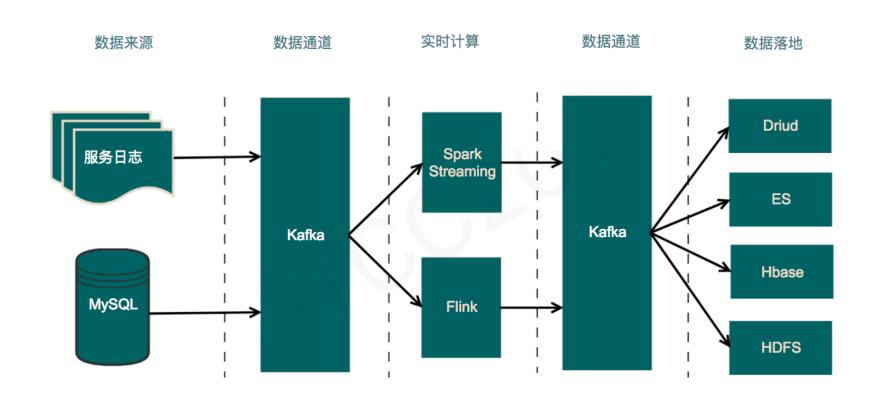
- 1. 千万/s 以上的流量,承担了滴滴80%的实时数据ETL工作
- 2. Spark Streaming任务数:约400+
- 3. 服务于快车、专车、顺风车、安全部、运维部等各个业务部门







#### 滴滴实时数据流转











#### Spark Streaming应用场景



- 海量异构数据处理,包括日志、binlog、事件消息等数据
- 低延迟、高吞吐
- 监控系统,数据质量系统等实时系统









#### 实时数据清洗特点

- 各种不规则的数据源
- 数据流量非常大(实时原始数据每秒上亿条记录)
- 清洗规则可以动态生效
- 清洗过程简单
- 整个过程可监控可告警









#### Spark Streaming—ETL实践

利用Spark Streaming实现了一套数据ETL产品

- 支持各种清洗规则(位置解析、正则表达、固定数据格式等)
- 在线清洗规则的动态更新
- 支持业务特征的自定义派生转换
- 整个ETL链路的可视化监控和告警
- At Least Once—致性保证



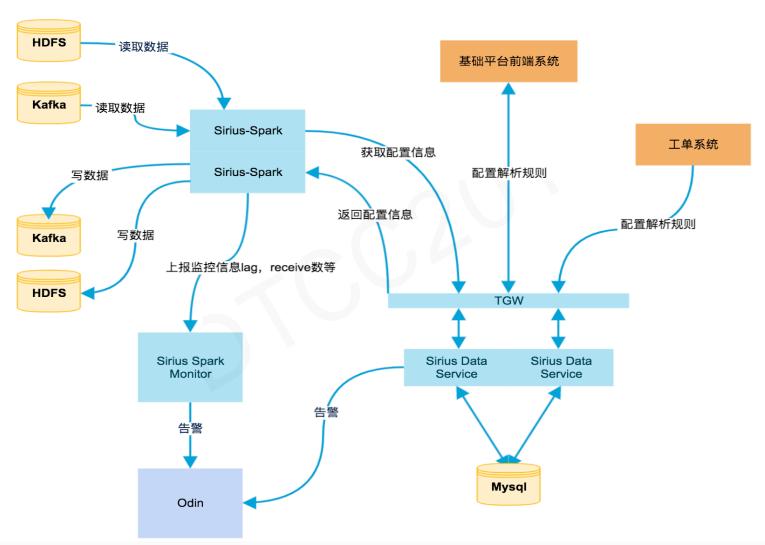








# Spark Streaming—ETL实践







#### Spark Streaming—ETL收益

- 服务后续上百个模块
- 数据清洗需求分钟级完成
- 承担了滴滴90%实时数据的清洗任务











#### Spark Streaming—ETL总结

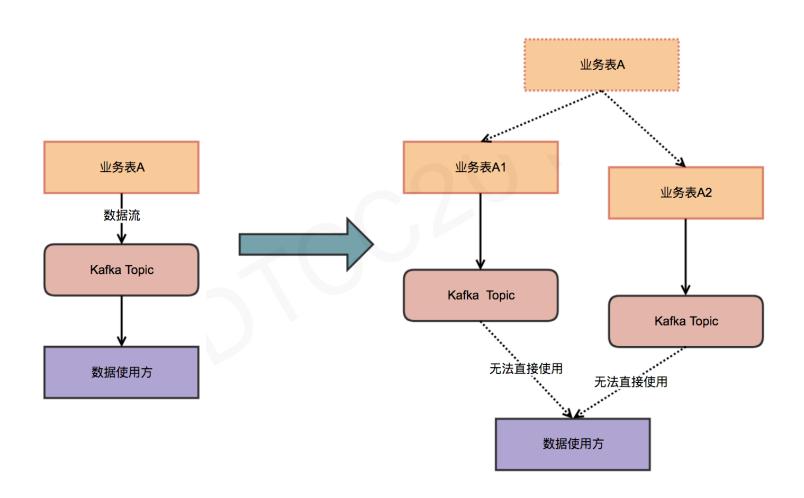
- 日志规范化,提高ETL的效率
- 构建数据地图,提高数据的复用率
- 数据血缘关系梳理,变更早感知
- 全链路数据质量监控、告警
- 隔离关键性数据处理
- 减少和外部系统的依赖







## Spark Streaming—多流问题





## Spark Streaming—多流Join实践

多个不同流根据一定规则join的问题(例如:顺风车发单流与接单流join问题)

#### 特点:

- 不同流需要join的时间跨度较长(例如:顺风车发单与接单时间跨度最长一周之久)
- 数据源格式不定 (例如:binlog数据和业务日志的join)
- join规则多样化
- 系统要求吞吐量大、延迟低(秒级)

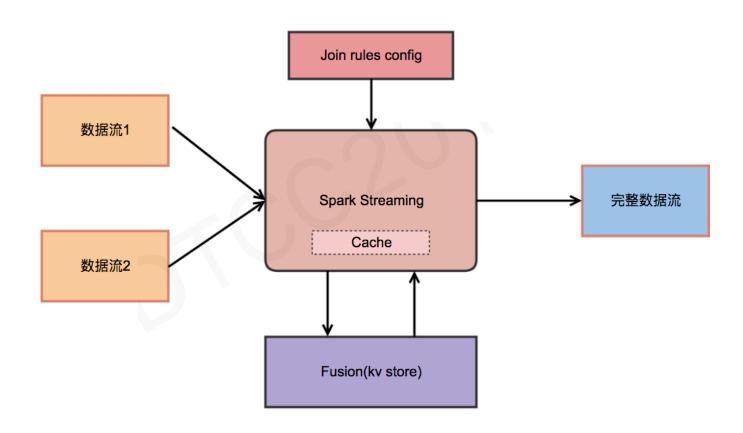








#### Spark Streaming—多流Join实践











## Spark Streaming—多流Join收益

- 提供BI监控(滴滴最重要的监控系统)核心数据源
- 为特征平台等业务提供数据源
- 为业务方提供快速的流join方案



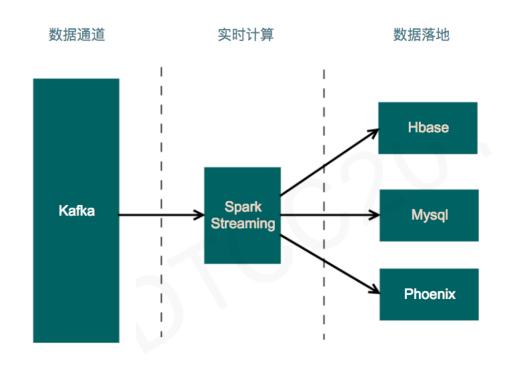








#### Spark Streaming—sink能力



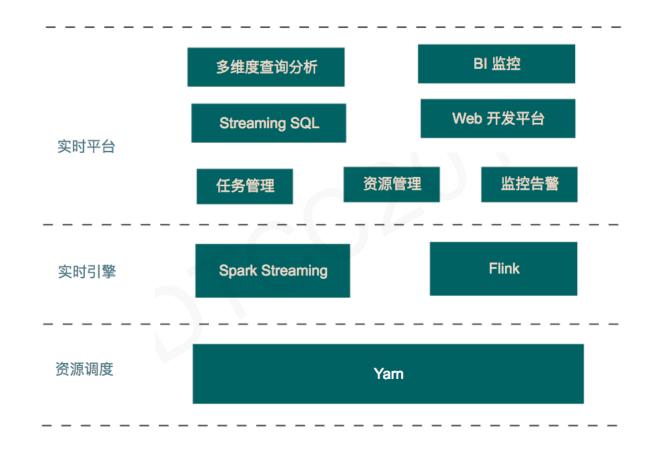








#### 实时平台











#### 实时平台—任务管理

作业配置						
	* 所属集群:	测试集群			90/ 480/c	
	7月周采标:	若没有项目请新建:		300		
	* 任务名称:					
		示例:客服部-数据可视化大照	<b>异项目</b>		00/2 00	
	* 任务类别:	spark2.2.0-500	1780:	80; <u> </u>		
		注: 切换任务类型时若存在已	上传依赖资源会被清除			
	* 主程序:	已上传资源	↑ 上传资源			
		主程序有且只有一个,允许上	传的文件类型:.jar/.py			
	checkpoint工作目录:	The state of the s		/		
	依赖资源:	十 增	加依赖资源			
		注意: 资源不可重复上传				
	* 主类名称:	05				
		eg: com.didi.spark.Stream	ingTest.WordCount			
14800	用户参数:	1080	37480°	*14800	1408	

- Web方式管理任务,减轻任务管理负担
- 提供参数调优实践
- 提供http任务管理接口,方便其他系统集成









#### 实时平台-作业监控告警



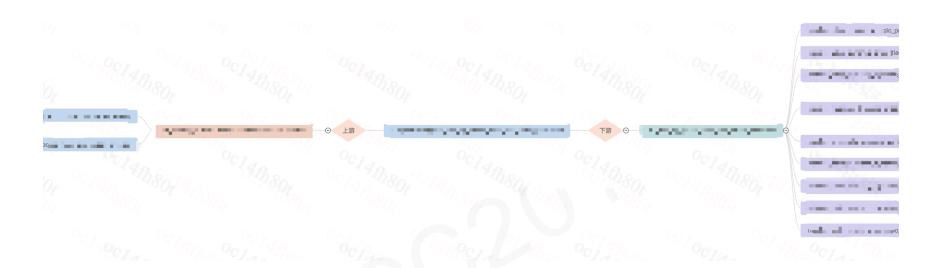
- Metrics上报kafka、实时平台进行展示和监控
- 提供各个维度的告警服务 (默认提供任务异常告警和任务延迟告警)
- · 一键导航作业UI及诊断系统







#### 实时平台—血缘关系



- Spark Streaming上报消费源和输出源,构建上下游实时数据血缘
- 方便构建链路告警体系
- 发现和管理链路依赖关系









#### 03 Spark Streaming最佳实践













#### Spark Streaming参数调优-解决大部分问题

- 开启反压: spark.streaming.backpressure.enabled
- 消费速度: spark.streaming.kafka.maxRatePerPartition
- kafka抖动导致 No leader found: spark.streaming.kafka.maxRetries
- driver端oom: spark.driver.memory
- 包冲突: spark.driver/executor.userClassPathFirst
- spark-streaming-kafka: --executor-cores \* --num-executors <= topicPartitons</li>
- Job级别的并发: spark.streaming.concurrentJobs









# Spark Streaming引擎改造-稳定性和易用性

- 支持保存kafka offset(利用kafka Api保存offset到zookeeper/kafka broker)
- 支持Spark Streaming on yarn平稳停止 (保证没有异常情况下的Exactly-Once语义)
- 增加自定义Metrics及Metrics上报Kafka的能力(丰富监控指标)
- · 升级Spark2.2依赖的kafka版本(增加稳定性)







#### Spark Streaming平台化实践

- 日志实时上报ES(根据关键字快速检索日志)
- 提供诊断系统,快速定位问题
- 沉淀详细的最佳实践和使用手册(增加平台易用性)
- 常见错误的归纳整理(极大方便小白用户)







# THANKS SQL Hadoop BigData NoSQL



讲师申请

联系电话(微信号): 18612470168

关注"ITPUB"更多技术干货等你来拿~

与百度外卖、京东、魅族等先后合作系列分享活动





# 让学习更简单

微学堂是以ChinaUnix、ITPUB所组建的微信群为载体,定期邀请嘉宾对热点话题、技术难题、新产品发布等进行移动端的在线直播活动。

截至目前,累计举办活动期数60+,参与人次40000+。

# **◯** ITPUB学院

ITPUB学院是盛拓传媒IT168企业事业部(ITPUB)旗下 企业级在线学习咨询平台 历经18年技术社区平台发展 汇聚5000万技术用户 紧随企业一线IT技术需求 打造全方式技术培训与技术咨询服务 提供包括企业应用方案培训咨询(包括企业内训) 个人实战技能培训(包括认证培训) 在内的全方位IT技术培训咨询服务

ITPUB学院讲师均来自于企业
一些工程师、架构师、技术经理和CTO
大会演讲专家1800+
社区版主和博客专家500+

#### 培训特色

无限次免费播放 随时随地在线观看 碎片化时间集中学习 聚焦知识点详细解读 讲师在线答疑 强大的技术人脉圈

#### 八大课程体系

基础架构设计与建设 大数据平台 应用架构设计与开发 系统运维与数据库 传统企业数字化转型 人工智能 区块链 移动开发与SEO



#### 联系我们

联系人: 黄老师

电 话: 010-59127187 邮 箱: edu@itpub.net 网 址: edu.itpub.net

培训微信号: 18500940168